

Optimisation pour l'Apprentissage Automatique

IASD Apprentissage

Cours 1

October 1, 2026

Shuyu Dong

Programme

- ▶ Introduction et méthodes de gradient
- ▶ Optimiseurs · Calcul de dérivées
- ▶ Différentiation automatique
- ▶ Problèmes convexes et non-convexes
- ▶ Gradients, sous-gradients · Méthodes proximales
- ▶ Méthodes de gradient et programmation linéaire

Evaluation :

- Examen écrit final
- 1 Projet final

Références :

- Supports du cours *Optimisation pour l'apprentissage automatique* de Clément Royer.
URL <https://www.lamsade.dauphine.fr/~croyer/coursOAA.html>.
- (Wright and Ma, 2022): High-dimensional data analysis with low-dimensional models: Principles, computation, and applications. Cambridge University Press.
URL <https://book-wright-ma.github.io/>.
- ▶ Autres références à détailler

Plan du cours

- ▶ 1.1 – Descente de gradient
- ▶ 1.2 – Exercices 1


Plan du cours

1.1 – Descente de gradient


1.2 – Exercices 1

Optimisation pour l'apprentissage automatique

Exemple :



(a) without skip connections



(b) with skip connections

Figure 1: The loss surfaces of ResNet-56 with/without skip connections. The proposed filter normalization scheme is used to enable comparisons of sharpness/flatness between the two figures.

(Li et al., 2018)

Optimisation pour l'apprentissage automatique

Exemple :




Figure 5: 2D visualization of the loss surface of ResNet and ResNet-noshort with different depth.

(Li et al., 2018)

Pourquoi des gradients ?

La descente de gradient est à l'origine de la plupart des algorithmes d'optimisation pour l'apprentissage, par exemple, des méthodes pour optimiser des réseaux de neurones.

Problème :

$$\underset{w \in \mathbb{R}^d}{\text{minimiser}} \quad f(w) \quad \text{où} \quad f : \mathbb{R}^d \rightarrow \mathbb{R} \quad \text{est de classe } C^1. \quad (1)$$

Les **variables / paramètres** sur lesquels on optimise sont

$$w = (w_1, \dots, w_d)^T = \begin{bmatrix} w_1 \\ \vdots \\ w_d \end{bmatrix}, \quad w_i \in \mathbb{R}.$$

Pour tout $w \in \mathbb{R}^d$, la variation de f autour de w est décrite par le vecteur gradient de f en w , noté

$$\nabla f(w) \in \mathbb{R}^d.$$

Pourquoi des gradients ? (cont.)

Proposition : *Toute solution du problème d'optimisation (1) est un point en lequel le gradient est nul. C'est à dire :*

$$w^* \in \arg \min_{w \in \mathbb{R}^d} f(w) \quad \implies \quad \nabla f(w^*) = 0.$$

Notation : on utilise “ $\nabla f(w^*) = 0$ ” pour l'expression $\nabla f(w^*) = (0, \dots, 0)^T \in \mathbb{R}^d$.

Preuve : Si le gradient $\nabla f(w)$ n'est pas nul, alors il existe un point v tel que $f(v) < f(w)$; il suffit de faire un petit déplacement (depuis w) dans la direction opposée du gradient $\nabla f(w)$ pour en trouver un tel point v . $\square$

L'ensemble des solutions (ou minima globaux) du problème est donc contenu dans l'ensemble des points où le gradient est nul.

Remarque : Il peut exister des points en lesquels le gradient est nul mais qui ne sont pas des solutions du problème.

Exemple : pour $d = 1$, $f(w) = \frac{1}{2}(w^2 - 1)^2$.

- ▶ Deux minima globaux (sur lesquels le gradient est nul)
- ▶ Mais il y a un point non-optimal sur lequel le gradient s'annule aussi.

Algorithme de descente de gradient

Algorithm 1 Descente de gradient

Initialisation : Choisir w_0

for $k = 0, 1, 2, \dots$

 Calculer le gradient $\nabla f(w_k)$

 Calculer $w_{k+1} = w_k - \alpha_k \nabla f(w_k)$ avec $\alpha_k > 0$

end for

Questions :

- ▶ Est-ce que cet algorithme fonctionne ?
- ▶ Comment l'implémenter (quelle initialisation, choix de α_k , critère d'arrêt, ...) ?

Algorithme de descente de gradient (cont.)

Exemple : Descente de gradient et la régression linéaire.

Etant donnée les échantillons $\{x_i, y_i\}_{i=1,\dots,m}$ où $x_i \in \mathbb{R}^d$ et $y_i \in \mathbb{R}$, on veut minimiser :

$$f(w) = \frac{1}{2m} \|Xw - y\|_2^2 = \frac{1}{2m} \sum_{i=1}^m (x_i^T w - y_i)^2,$$

avec $X = (x_1, \dots, x_m)^T \in \mathbb{R}^{m \times d}$ et $w \in \mathbb{R}^d$.

- f est différentiable et son gradient vaut :

$$\nabla f(w) = \frac{1}{m} X^T (Xw - y).$$

- On peut appliquer la descente de gradient à ce problème :

$$w_{k+1} = w_k - \frac{\alpha_k}{m} X^T (Xw_k - y)$$

Notation : pour tout $u, v \in \mathbb{R}^n$, on note $u^T v := \sum_{i=1}^n u_i v_i$ pour le produit scalaire, et $\|u\|_2^2 := \sum_{i=1}^n u_i^2$ pour la norme ℓ_2 .

Remarque :

- ▶ Si $\nabla f(w_k) = 0$, alors $w_{k+1} = w_k - \alpha_k \nabla f(w_k) = w_k - 0 = w_k$.

Algorithme de descente de gradient (cont.)

- L'itération se réécrit :

$$w_{k+1} = \left[I - \frac{\alpha_k}{m} X^T X \right] w_k + \frac{\alpha_k}{m} X^T y$$

- En combinant cette formule sur plusieurs itérations, on peut garantir (sous certaines hypothèses) que la méthode converge vers une solution du problème :
 1. Soit on atteint un point fixe.
 2. Soit $\lim_{k \rightarrow \infty} \{w_k\} = w^*$ qui minimise $f(w)$.
- En pratique, on cherche à converger le plus rapidement possible dans un budget imparti. La descente de gradient garantit une vitesse de convergence en un nombre d'itérations fixé.

Théorème (Convergence de la descente de gradient pour la régression linéaire) : *Supposons qu'il existe $w^* \in \mathbb{R}^d$ tel que $Xw^* = y$, et que $X^T X$ est définie positive. On utilise la descente de gradient (Algorithm 1) avec $\alpha_k = \frac{m}{\|X^T X\|}$. Alors, la suite des itérés $\{w_k\}_{k \geq 0}$ de la descente de gradient vérifie :*

$$\|w_k - w^*\|_2^2 \leq \rho^k \|w_0 - w^*\|_2^2 \quad \text{avec } \rho \text{ telle que } 0 \leq \rho < 1.$$

Preuve : (à voir au tableau)

Algorithme de descente de gradient (cont.)

Par conséquent, on a alors $\lim_{k \rightarrow \infty} \|w_k - w^*\|_2 = 0$, et on dit que la descente de gradient converge sur ce problème en **vitesse linéaire**.

Remarque : Si w^* satisfait $Xw^* = y$, alors :

$$\nabla f(w^*) = \frac{1}{m} X^T (Xw^* - y) = 0 \in \mathbb{R}^d$$

et

$$f(w) = \frac{1}{2m} \|Xw - y\|_2^2 \geq 0 = \frac{1}{2m} \|Xw^* - y\|_2^2 = f(w^*) \quad \forall w \in \mathbb{R}^d$$

Ainsi, $f(w) \geq f(w^*)$, $\forall w \in \mathbb{R}^d$, i.e., $w^* \in \arg \min_{w \in \mathbb{R}^d} f(w)$.

Convergence linéaire au-delà de la régression linéaire

Pour un problème

$$\underset{w \in \mathbb{R}^d}{\text{minimise}} f(w), \text{ avec } f \text{ fortement convexe,}$$

on peut montrer que $\|w_k - w^*\|$ décroît à une vitesse linéaire, où w_k est obtenu par k itérations d'une descente de gradient.

Definition : f est de classe $C_L^{1,1}$ si $f \in C^1$ et ∇f est L -lipschitzien.

Remarque :

- ∇f est L -lipschitzien $\iff \forall (v, w) \in \mathbb{R}^d \times \mathbb{R}^d, \quad \|\nabla f(v) - \nabla f(w)\| \leq L\|v - w\|.$
- Lorsque v est proche de w , $\nabla f(v)$ est proche de $\nabla f(w)$.

Les résultats pour la régression linéaire s'étendent à toute fonction $C_L^{1,1}$ et fortement convexe.

Definition :

- $f : \mathbb{R}^d \rightarrow \mathbb{R}$ de classe C^1 est **convexe** si et seulement si :

$$\forall (v, w) \in \mathbb{R}^d \times \mathbb{R}^d, \quad f(v) \geq f(w) + \nabla f(w)^T (v - w).$$

Convergence linéaire au-delà de la régression linéaire (cont.)

- $f : \mathbb{R}^d \rightarrow \mathbb{R}$ de classe C^1 est μ -**fortement convexe** ($\mu > 0$) si et seulement si :

$$\forall (v, w) \in \mathbb{R}^d \times \mathbb{R}^d, \quad f(v) \geq f(w) + \nabla f(w)^T (v - w) + \frac{\mu}{2} \|v - w\|_2^2.$$

Exemple : La régression linéaire est définie via une fonction convexe, qui est fortement convexe lorsque $X^T X$ est définie positive (auquel cas $\mu = \sigma_{\min}(X^T X) > 0$).

Exemple : Régression logistique

$$\underset{w \in \mathbb{R}^d}{\text{minimiser}} \quad \frac{1}{m} \sum_{i=1}^m \log \left(1 + e^{-y_i x_i^T w} \right) + \frac{\lambda}{2} \|w\|_2^2$$

avec $x_i \in \mathbb{R}^d$, $y_i \in \{-1, +1\}$, $\lambda \geq 0$.

- La fonction objectif est toujours convexe et elle est λ -fortement convexe si $\lambda > 0$.
- Elle est $C_L^{1,1}$ avec $L = \frac{4\|X^T X\|}{m} + \lambda$.

Propriétés des fonctions (fortement) convexes

Proposition :

- ▶ Si f est C^1 et convexe, alors $w^* \in \arg \min_w f(w)$ si et seulement si $\nabla f(w^*) = 0$.
- ▶ Si f est C^1 et fortement convexe, alors il existe une unique solution au problème ($\arg \min_w f(w)$ contient un seul élément).

Exemple :

$$f(w) = \frac{1}{4} \|Xw - y\|_2^2, \quad d = 2, \quad X = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

f est convexe (pas fortement convexe).

$$\arg \min_w f(w) = \left\{ (1, w_2)^T : w_2 \in \mathbb{R} \right\}$$

Exemple :

$$\hat{f}(w) = \frac{1}{4} \|\hat{X}w - y\|_2^2, \quad \hat{X} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$\hat{f}$ est fortement convexe.

$$\arg \min_w \hat{f}(w) = \left\{ (1, 1)^T \right\}$$

Propriétés des fonctions (fortement) convexes (cont.)

Théorème : Soit $f : \mathbb{R}^d \rightarrow \mathbb{R}$ une fonction $C_L^{1,1}$ convexe et soit $\{w_k\}_{k \geq 0}$ la suite des itérés de la descente de gradient avec $\alpha_k = \frac{1}{L}$. Alors :

$$f(w_k) - \min_{w \in \mathbb{R}^d} f(w) \leq \mathcal{O}\left(\frac{1}{k}\right).$$

Notes :

- ▶ $\min_{w \in \mathbb{R}^d} f(w)$ est la valeur optimale du problème.
- ▶ $\mathcal{O}(A)$: une quantité entre $c_1 A$ et $c_2 A$ pour deux constants $0 < c_1 \leq c_2$.
- ▶ Ici, $\mathcal{O}\left(\frac{1}{k}\right) = \frac{L}{2k} \cdot \text{dist}^2(w_0, \arg \min_w f(w))$.

On dit que la descente de gradient converge en $\mathcal{O}\left(\frac{1}{k}\right)$ dans le cas convexe.

Propriétés des fonctions (fortement) convexes (cont.)

Théorème : Si de plus f est μ -fortement convexe, alors :

$$f(w_k) - \min_{w \in \mathbb{R}^d} f(w) \leq \mathcal{O} \left(\left(1 - \frac{\mu}{L}\right)^k \right).$$

Remarque :

Le rapport $\kappa = \frac{L}{\mu} \geq 1$ est appelé le conditionnement du problème.

- ▶ Plus κ est proche de 1, plus la convergence est rapide.
- ▶ Plus κ est grand, plus le problème est dit mal conditionné, et la convergence ralentit.

La descente de gradient converge en $\mathcal{O}(\rho^k)$ (ou en vitesse linéaire) dans le cas fortement convexe.

- ▶ Une meilleure vitesse de convergence que dans le cas convexe ($\rho^k \rightarrow 0$ plus vite que $\frac{1}{k}$).

- ▶ Le gradient (quand il existe) vaut 0 en tout minimum global.
 - Si la fonction est convexe, les seuls points où le gradient vaut 0 sont les minima globaux.
 - Si la fonction est fortement convexe, il existe un unique minimum global.
- ▶ L'algorithme de descente de gradient s'applique pour tout problème où la fonction à minimiser est C^1 .
 - Si elle est $C_L^{1,1}$, on peut utiliser $\alpha_k = \frac{1}{L}$ dans l'algorithme.
 - Cela garantit une vitesse de convergence, notamment dans les cas convexe et fortement convexe.

Plan du cours

1.1 – Descente de gradient

1.2 – Exercices 1

Thank You !

References

- Li, H., Xu, Z., Taylor, G., Studer, C., and Goldstein, T. (2018). Visualizing the loss landscape of neural nets. *Advances in neural information processing systems*, 31.
- Wright, J. and Ma, Y. (2022). *High-dimensional data analysis with low-dimensional models: Principles, computation, and applications*. Cambridge University Press.