

Exercices : Descente de gradient

Optimisation pour l'apprentissage automatique

M2 IASD Apprentissage, 2026-2027



Exercice 1 : Régression linéaire standard

Dans cet exercice, on considère un jeu de données de la forme $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ où $\mathbf{x}_i \in \mathbb{R}^d$ et $y_i \in \mathbb{R}$ pour $i = 1, \dots, n$. On pose $\mathbf{y} = [y_i] \in \mathbb{R}^n$ et $\mathbf{X} = [\mathbf{x}_i^T] \in \mathbb{R}^{n \times d}$. On cherche un modèle linéaire qui associe les $\mathbf{x}_i$ aux y_i , ce que l'on formule comme le problème d'optimisation suivant :

$$\underset{\mathbf{w} \in \mathbb{R}^d}{\text{minimiser}} f^{\text{lin}}(\mathbf{w}) := \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 = \frac{1}{2n} \sum_{i=1}^n (\mathbf{w}^T \mathbf{x}_i - y_i)^2. \quad (1)$$

- a) La valeur optimale du problème (1) est-elle nécessairement 0?
- b) La fonction objectif du problème (1) est convexe et de classe $\mathcal{C}^1$. Donner une caractérisation des solutions du problème (1) basée sur le gradient de f^{lin} .
- c) Écrire l'itération de descente de gradient appliquée au problème (1) en utilisant une suite de longueurs de pas $\{\alpha_k\}$. Donner deux choix possibles pour cette suite.
- d) Donner la vitesse de convergence de la descente de gradient sur un tel problème convexe. À quelle quantité cette vitesse s'applique-t-elle ?
- e) On suppose maintenant que les données sont telles que la fonction objectif f^{lin} du problème (1) est μ -fortement convexe et de classe $\mathcal{C}_L^{1,1}$ (son gradient est donc L -lipschitzien).
 - i) Que peut-on dire des minima locaux d'une fonction fortement convexe ?
 - ii) Quelle est la vitesse de convergence de la descente de gradient sur un tel problème ?

Exercice 2: Réseaux linéaires à une couche

Dans cet exercice, on considère un jeu de données à labels scalaires, à savoir $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ où $\mathbf{x}_i \in \mathbb{R}^{d_x}$ et $y_i \in \mathbb{R}$ pour tout $i = 1, \dots, n$. On construit une architecture neuronale

très basique avec une seule couche linéaire homogène et pas d'activation, afin de prédire la valeur y_i à partir du vecteur x_i : le modèle obtenu est ainsi

$$\begin{aligned} h^{lin}(\cdot; \mathbf{w}) : \mathbb{R}^{d_x} &\longrightarrow \mathbb{R}^{d_y} \\ \mathbf{x} &\longmapsto \mathbf{W}_1 \mathbf{x}, \end{aligned} \quad (2)$$

avec $\mathbf{W}_1 \in \mathbb{R}^{1 \times d_x}$. En posant $d = d_x$ et $\mathbf{w} = \mathbf{W}_1^T \in \mathbb{R}^d$, on formule le problème de déterminer le meilleur modèle comme suit :

$$\underset{\mathbf{w} \in \mathbb{R}^d}{\text{minimiser}} f^{lin}(\mathbf{w}) := \frac{1}{2n} \sum_{i=1}^n (\mathbf{w}^T \mathbf{x}_i - y_i)^2. \quad (3)$$

- a) La formulation (3) correspond à un problème bien connu en apprentissage. Quel est ce problème ?
- b) La fonction objectif f^{lin} est $\mathcal{C}_L^{1,1}$ (son gradient est L -lipschitzien). Lorsque la valeur de L est connue, comment celle-ci peut-elle être employée dans un algorithme tel que la descente de gradient ?
- c) Le problème (3) est convexe avec une fonction objectif de classe $\mathcal{C}^1$.
 - i) Que peut-on dire d'un point $\bar{\mathbf{w}}$ tel que $\nabla f^{lin}(\bar{\mathbf{w}}) = \mathbf{0}_{\mathbb{R}^d}$?
 - ii) On peut obtenir une vitesse de convergence pour la descente de gradient sur ce problème. De quoi s'agit-il, et à quelle(s) quantité(s) s'applique la vitesse de convergence dans le contexte de cette question ?
- d) On suppose dans cette question que les données sont telles que f^{lin} soit μ -fortement convexe, en plus des propriétés mentionnées plus haut.
 - i) Soient $\mathbf{w}, \mathbf{v} \in \mathbb{R}^d$ deux vecteurs tels que $\nabla f^{lin}(\mathbf{w}) = \nabla f^{lin}(\mathbf{v}) = \mathbf{0}_{\mathbb{R}^d}$. Que peut-on dire de $\mathbf{v}$ et $\mathbf{w}$?
 - ii) La complexité de la descente de gradient dans ce cas est-elle meilleure que celle de la question c)ii) ?

Exercice 3: Réseaux linéaires à deux couches

Soit un jeu de données $\{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^n$ avec $\mathbf{x}_i \in \mathbb{R}^{d_x}$ et $\mathbf{y}_i \in \mathbb{R}^{d_y}$. Notre objectif est d'apprendre une fonction de $\mathbb{R}^{d_x}$ dans $\mathbb{R}^{d_y}$ qui renvoie $\mathbf{y}_i$ lorsque $\mathbf{x}_i$ est passé en entrée. Le modèle que l'on choisit ici est celui d'un réseau de neurones à deux couches linéaires :

$$\begin{aligned} h(\cdot; \mathbf{w}) : \mathbb{R}^{d_x} &\longrightarrow \mathbb{R}^{d_y} \\ \mathbf{x} &\longmapsto \mathbf{W}_2(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2, \end{aligned} \quad (4)$$

où $\mathbf{W}_1 \in \mathbb{R}^{d_x \times m}$, $\mathbf{b}_1 \in \mathbb{R}^m$, $\mathbf{W}_2 \in \mathbb{R}^{m \times d_y}$ et $\mathbf{b}_2 \in \mathbb{R}^{d_y}$. On considère que le modèle h est paramétré par $\mathbf{w} \in \mathbb{R}^d$, où $d = d_x m + m + m d_y + d_y$ et $\mathbf{w}$ représente tous les coefficients de $\mathbf{W}_1, \mathbf{b}_1, \mathbf{W}_2, \mathbf{b}_2$ mis sous forme vectorielle. Notre but est de déterminer une valeur de $\mathbf{w}$ telle que $h(\mathbf{x}_i; \mathbf{w}) \approx \mathbf{y}_i$ pour tout i , ce que l'on quantifie au moyen d'une fonction de perte aux moindres carrés.

Au final, on obtient le problème suivant

$$\underset{\mathbf{w} \in \mathbb{R}^d}{\text{minimiser}} f(\mathbf{w}) := \frac{1}{2n} \sum_{i=1}^n \|h(\mathbf{x}_i; \mathbf{w}) - \mathbf{y}_i\|^2. \quad (5)$$

- a) Donner un minorant de la fonction objectif du problème (5).
- b) En général, le problème (5) est non convexe. Que cela implique-t-il concernant l'ensemble de ses minima locaux et celui de ses minima globaux?
- c) La fonction f est de classe $\mathcal{C}^1$.
 - i) Supposons que w^* soit une solution de (5). Que peut-on dire de la dérivée de f en w^* ?
 - ii) Écrire l'itération de la descente de gradient appliquée au problème (5) avec une longueur de pas non spécifique.
 - iii) Donner deux stratégies possibles pour choisir cette longueur de pas.
 - iv) Ce problème est non convexe : sur quelle quantité peut-on alors donner des garanties de complexité dans ce cadre ? Ces garanties sont-elles meilleures que pour un problème convexe ?